

Análisis Multidimensional de la Calidad de Vida en España

Linxi Jiang
Stefano Bia
Carlos Salas
David Muñoz



Análisis técnico sobre la influencia de factores económicos y medioambientales con la calidad de vida en España. Este proyecto implementa una arquitectura de datos completa para unificar indicadores económicos y ambientales, transformando información heterogénea en un Grafo de Conocimiento enriquecido y explotable.

Introducción

Contexto general

Este proyecto presenta una solución integral de ingeniería de datos para evaluar los factores determinantes del bienestar en las Comunidades Autónomas. A través de un pipeline ETL híbrido y la transformación a grafos de conocimiento (Linked Data enriquecido con Wikidata), unificamos fuentes heterogéneas de economía, demografía y contaminación. El objetivo es responder, mediante datos objetivos, cómo influye el entorno económico y ambiental en la calidad de vida de la ciudadanía.

Objetivos de la práctica

- **Integración de Fuentes Heterogéneas:** Unificar en un único almacén de datos indicadores económicos estructurados (INE) junto con series temporales de sensores de contaminación (datos semi-estructurados), superando la fragmentación de la información.
- **Procesamiento ETL Híbrido:** Implementar un pipeline de limpieza avanzado combinando Pentaho Data Integration para la estandarización y Python para la inferencia de valores nulos y normalización de formatos numéricos complejos.
- **Interoperabilidad Semántica (Linked Data):** Transformar los datos tabulares en un Grafo de Conocimiento utilizando el estándar RDF y ontologías como Schema.org, garantizando que la información sea comprensible por máquinas.
- **Enriquecimiento Contextual:** Conectar las entidades locales (Comunidades Autónomas) con la nube de Linked Open Data a través de Wikidata, permitiendo la desambiguación y el acceso a datos federados externos.
- **Visualización para la Toma de Decisiones:** Generar gráficos que permitan validar la hipótesis inicial: determinar si existe una correlación negativa entre el desarrollo económico (PIB) y la salud ambiental en la calidad de vida ciudadana.

Enlaces: [Github](#) | [Página de Visualizaciones](#)

Evaluar las necesidades de los datos

1.1 Introducción

El dominio seleccionado para este proyecto es el Bienestar Social y Sostenibilidad Ambiental. Específicamente, nos centramos en el análisis multidimensional de la calidad de vida en España, cruzando indicadores socioeconómicos tradicionales con métricas de salud ambiental. Hemos identificado que los indicadores macroeconómicos (como el PIB) a menudo son insuficientes para explicar el bienestar real de la ciudadanía si no se contextualizan con factores externos como la contaminación o la desigualdad económica.

1.2 Identificación del problema

- **WHO (Interesados):**
 - **Ciudadanía:** Personas que desean tomar decisiones informadas sobre dónde vivir buscando un equilibrio entre oportunidades laborales (economía) y salud (medio ambiente).
 - **Administraciones Públicas:** Gobiernos autonómicos que necesitan evaluar la eficiencia de sus políticas públicas no solo en términos de riqueza generada, sino de bienestar social percibido.
 - **Investigadores y Urbanistas:** Profesionales que requieren datos unificados para estudiar el impacto de la industrialización en la salud pública.
- **WHAT (Problema o necesidad):**
 - La información sobre calidad de vida se encuentra actualmente fragmentada y dispersa. Los datos económicos (INE) están separados de los datos ambientales (sensores de calidad del aire), y ambos carecen de una conexión semántica que permita su explotación conjunta. Existe una necesidad crítica de integrar fuentes heterogéneas para responder si el crecimiento económico conlleva un deterioro ambiental que lastra la calidad de vida.
- **WHERE (Dónde y cuándo):**
 - **Contexto geográfico:** Comunidades Autónomas de España (Nivel NUTS-2).
 - **Contexto temporal:** Análisis de series temporales recientes (última década), con especial foco en la evolución post-pandemia donde la disponibilidad de datos abiertos ha aumentado.
- **WHY (Importancia):**
 - **Impacto social:** Permitir el paso de una gestión basada en intuiciones a una política basada en la evidencia (Evidence-Based Policy). Maximizar la eficacia de las inversiones.
 - **Beneficio:** Demostrar y cuantificar el "peaje ambiental": determinar si las regiones más ricas son, paradójicamente, lugares peores para vivir debido a la contaminación, o si la riqueza permite mejores infraestructuras verdes.

1.3 Preguntas de competencia

El proyecto busca responder a las siguientes preguntas clave, identificadas en la fase inicial:

- ¿Cómo influye la economía de una CCAA en la calidad de vida de sus habitantes? (Correlación Renta/PIB vs. Índice de Calidad de Vida).
- ¿Cómo influye la contaminación en el bienestar percibido?
- ¿Qué factor es más determinante? Analizar si pesa más la desigualdad económica (Gini) o la salud ambiental en la puntuación final de calidad de vida.

1.4 Objetivos del proyecto

- **Ingesta Unificada:** Crear un repositorio centralizado que combine datos estructurados (CSV del INE) y datos de sensores ambientales.
- **Calidad del Dato:** Asegurar la consistencia de la información mediante procesos ETL que gestionen valores nulos y normalicen formatos.
- **Interoperabilidad Semántica:** Transformar los datos a Linked Data (RDF) enriquecidos con Wikidata para garantizar su reutilización y conexión con estándares europeos.
- **Visualización:** Prover cuadros de mando que permitan la exploración interactiva de las correlaciones.
- **Reproducibilidad:** Crear un proceso reproducible, permitiendo a cualquiera reproducir nuestros resultados de forma sencilla y a su vez facilitando enormemente añadir o actualizar los datos de entrada.

1.5 Métricas clave

Para evaluar el éxito del análisis, se monitorizarán los siguientes indicadores (KPIs):

- **Económicos:** PIB per cápita, Renta Neta Media, IPC, Índice Gini.
- **Demográficos:** Densidad de población.
- **Ambientales:** Concentración media anual de contaminantes (NO₂, PM₁₀, O₃).
- **Sintético:** Índice de la Calidad de Vida (QOL).

Diseño del Almacén de Datos

Para consolidar la información heterogénea proveniente del INE y los sensores ambientales, se ha diseñado un almacén de datos centralizado siguiendo el paradigma multidimensional.


Diseño Conceptual

Se ha optado por un modelo en estrella para facilitar las consultas analíticas.

- **Tabla de Hechos (*fact_calidad_vida*):** Centraliza todas las métricas numéricas del estudio, incluyendo indicadores socioeconómicos (PIB, IPC, Gini), demográficos (Población, Esperanza de vida) y ambientales (Nivel de Contaminación).
- **Dimensiones:** El análisis se articula a través de dos dimensiones clave: *dim_tiempo* (para la evolución anual) y *dim_ccaa* (para el desglose geográfico).

Diseño Lógico

El modelado se ha realizado utilizando la herramienta MySQL Workbench, definiendo una arquitectura ROLAP. Se han establecido las claves primarias y las relaciones de cardinalidad (Foreign Keys) necesarias para vincular las métricas con sus contextos temporal y espacial.



Diseño Físico

El diseño se ha materializado en un script SQL (*physic.sql*) que genera la estructura de tablas (CREATE TABLE) en un Sistema Gestor de Bases de Datos MySQL/MariaDB, listo para la carga de datos.

Limpieza y Transformación de Datos

Para garantizar la calidad y homogeneidad del almacén de datos, se ha implementado un proceso ETL (Extract, Transform, Load) automatizado. La arquitectura elegida es híbrida: utilizamos Pentaho Data Integration (Kettle) para la orquestación y el tratamiento de datos estructurados (INE), y scripts de Python integrados en el flujo para el preprocesamiento de datos complejos (sensores de contaminación).

4.1 Orquestación del flujo de trabajo (Job)

El proceso se gobierna mediante el trabajo maestro `data.kjb`. Este Job coordina la ejecución secuencial de las tareas, asegurando la integridad referencial y el orden correcto de carga.

- **Gestión de Entorno:** Pasos como Create a folder y Delete folder preparan el área de trabajo (staging area) en cada ejecución.
- **Ejecución Híbrida (Shell Step):** El paso Shell (poll) ejecuta los scripts de Python encargados de la inferencia de vecinos y limpieza de datos de contaminación, integrando la salida en el flujo de Pentaho.
- **Sincronización:** Pasos como Wait for file aseguran que los archivos CSV necesarios estén disponibles antes de lanzar las transformaciones de agregación.

4.2 Transformación y limpieza (KTRs)

Se han diseñado transformaciones específicas (ej. `gini_ccaa.ktr`, `pob_ccaa.ktr`) para cada fuente de datos, aplicando las siguientes operaciones de limpieza:

- **Filtrado de filas:**
 - En `pob_ccaa.ktr`, se filtra la serie temporal para obtener solo los registros correspondientes al "1 de enero" de cada año, quedándonos solo con datos anuales.
 - En `gini_ccaa.ktr` y `pibc_ccaa.ktr`, se eliminan filas de metadatos o agregados nacionales no deseados para mantener solo el nivel de granularidad CCAA.
- **Normalización de cadenas y tipos:**
 - Uso del paso String Operations para estandarizar los nombres de las Comunidades Autónomas (ej. lower case, trim), permitiendo el cruce posterior de datos.
 - Corrección de anomalías de texto mediante Replace String (ej. eliminación de caracteres extraños en `pibc_ccaa.ktr`).
- **Estandarización numérica:**
 - Uno de los mayores retos fue la heterogeneidad en los formatos numéricos: origen español con coma decimal vs. anglosajón con punto.
 - En la transformación `agg_all.ktr`, se normalizan masivamente los campos (QOL, POLL) reemplazando comas por puntos antes de la conversión a tipo numérico, evitando errores de inserción en la base de datos.

4.3 Agregación Final

La transformación `agg_all.ktr` actúa como el embudo final del proceso. Recibe los flujos de datos limpios de las diferentes ramas (Economía, Demografía, Calidad de Vida), selecciona las métricas relevantes mediante pasos Select Values y genera el dataset maestro unificado (`data.csv`) que alimentará tanto la generación de grafos RDF como las visualizaciones.

Transformación a Grafos de Conocimiento

Para superar las limitaciones del modelo relacional y permitir la interoperabilidad de los datos a escala web, se ha implementado una capa de transformación semántica. El objetivo ha sido convertir los datos tabulares limpios (*dist/kettle/*.csv*) en un Grafo de Conocimiento basado en el estándar RDF (Resource Description Framework).

5.1 Tecnología e implementación

La transformación se ha automatizado mediante un script desarrollado en Python (*code/transform_rdf.py*), utilizando la librería especializada RDFLib. Esta decisión técnica se justifica por su robustez frente a herramientas visuales como OpenRefine, permitiendo:

- Ejecución desatendida: El script procesa masivamente todos los archivos CSV del directorio de salida de Pentaho.
- Escalabilidad: El código es modular y permite añadir nuevas fuentes de datos simplemente registrándolas en una lista de configuración.

5.2 Modelado ontológico (Schema.org)

Se ha seleccionado la ontología Schema.org por ser el estándar de facto para el etiquetado de datos en la web. El modelo de datos diseñado sigue una estructura de Observación Estadística:

- **Entidades Geográficas (*schema:Place*):** Las Comunidades Autónomas se modelan como instancias de la clase *schema:AdministrativeArea*.
- **Observaciones (*schema:Observation*):** Cada dato numérico se instancia como un objeto *schema:Observation*, conectando mediante propiedades semánticas, entre otras:
 - ***schema:variableMeasured*:** La métrica (ej. "Renta Neta Media").
 - ***schema:value*:** El valor numérico tipado (*xsd:float*).
 - ***schema:observationDate*:** La dimensión temporal (*xsd:gYear*).
 - ***schema:areaServed*:** La relación con la entidad geográfica correspondiente.
- **Agrupaciones (*schema:Dataset*):** Agrupamos las observaciones por Año y por CCAA para facilitar futuras queries.

5.3 Enriquecimiento con Linked Open Data (LOD)


Un componente crítico del proyecto ha sido la integración con la nube de datos abiertos enlazados. El script implementa un diccionario de mapeo que inyecta automáticamente enlaces *schema:sameAs* y *owl:sameAs* conectando cada recurso local con su identificador único en Wikidata. Este enriquecimiento permite la desambiguación de las entidades y habilita futuras consultas federadas para cruzar nuestros datos internos con la vasta base de conocimiento de Wikidata (por ejemplo, para obtener datos de superficie o población histórica sin necesidad de almacenarlos localmente). La ejecución del proceso genera un conjunto de archivos .ttl validados, que constituyen un grafo de conocimiento coherente listo para su publicación y explotación semántica. Además, también se define el tipo de dato o variable que define cada observación usando otras ontologías como son CHEBI, ECTO, ENVO y LFID.

Resultados y Conclusiones


La ejecución de este proyecto ha permitido validar la viabilidad técnica de construir un ecosistema de datos unificado para la toma de decisiones en el ámbito público. Tras completar el ciclo de vida de los datos, desde la extracción heterogénea hasta la explotación semántica, extraemos las siguientes conclusiones.

Análisis de resultados

Los resultados obtenidos mediante el script de análisis automatizado (*visual.py*) nos ofrecen una visión cuantitativa de los pesos que cada dimensión ejerce sobre la Calidad de Vida.



Esta gráfica demuestra que hay una correlación lineal positiva entre la economía y el bienestar, las rectas de regresión confirman que un mayor PIB por cápita significa una mejor calidad de vida. Hay una divergencia entre las mediciones nominales y las ajustadas por unidad de consumo en los tramos avanzados del eje X, indicando que en las regiones más ricas el coste de vida actúa como un factor de corrección que reduce el poder adquisitivo real, sugiriendo que el crecimiento nominal sobreestima la mejora en el bienestar si no se descuenta la inflación.



Este análisis muestra una tendencia negativa, indicando que la masificación demográfica y la degradación ambiental actúan como penalizadores directos del bienestar. Las pendientes descendentes de las regresiones sugieren que a medida que una comunidad crece en población o contaminación por encima de la media, su índice de calidad de vida se degrada. Se puede observar cómo la concentración demográfica tiene una pendiente negativa mayor que la contaminación, por lo que el estrés urbano podría ser un factor más determinante que la calidad del aire.

Conclusiones técnicas

- **Manejo de la Heterogeneidad:** La arquitectura híbrida ha permitido unificar fuentes dispares con éxito, integrando datos estructurados del INE y series temporales de sensores en un almacén de datos normalizado y consistente.
- **Potencial del Grafo de Conocimiento:** El uso de Linked Data y la conexión con Wikidata dotan al sistema de semántica y escalabilidad, permitiendo el enriquecimiento automático y las consultas federadas sin alterar la infraestructura local.
- **Visualización y Reproducibilidad:** El diseño modular y el script `start.sh` asegura la total reproducibilidad del proceso técnico, mientras que las visualizaciones transforman las métricas complejas en evidencia clara y accesible para la toma de decisiones.